

PROPOSAL PROJECT DATA MINING

**Analisis Deteksi Anomali pada Indikator Makroekonomi Global
sebagai Instrumen *Early Warning System* (EWS) Krisis Ekonomi**



Disusun oleh:

Kelompok 4

AMIR SYAIFUDIN	(222312968)
AGUSTINA BELADEWIANA MADU	(222312947)
BRAMANTYO PUTRA RACHMANDANI	(222313021)
M. REZKY RAYA KILWOUW	(222313190)
MUHAMMAD DAFFA DEKANANDA	(222313233)
NYIMAS VIRNA SALSA LESTARI RISQIA	(222313307)

**PROGRAM STUDI DIV KOMPUTASI STATISTIK
POLITEKNIK STATISTIKA STIS
2025/2026**

DAFTAR ISI

DAFTAR ISI.....	2
BAB I.....	4
PENDAHULUAN	4
1.1 Latar Belakang	4
1.2 Identifikasi Masalah.....	6
1.3 Tujuan	7
BAB II	8
KAJIAN LITERATUR	8
2.1 Konsep Definisi	8
2.1.1 Konsep Dasar Krisis Ekonomi dan Early Warning System	8
2.1.1.1 Krisis Ekonomi dan Tipologinya	8
2.1.1.2 Early Warning System (EWS)	8
2.1.1.3 Indikator Makroekonomi sebagai Sinyal EWS	9
2.1.2 Anomali dan Deteksi Anomali	9
2.1.2.1 Definisi dan Tipologi Anomali.....	9
2.1.2.2 Anomali dalam Konteks Data Deret Waktu Makroekonomi.....	10
2.1.3 Metode Deteksi Anomali Unsupervised	10
2.1.3.1 Isolation Forest	10
2.1.3.2 Local Outlier Factor (LOF).....	12
2.1.3.3 Autoencoder Neural Network	14
2.1.3.4 One-Class Support Vector Machine (OCSVM).....	15
2.1.3.5 PCA-based Anomaly Detection	16
2.1.3.6 DBSCAN (Density-Based Spatial Clustering of Applications with Noise).....	18
2.2 Penelitian Terkait	19
2.3 Kerangka Pikir	21
BAB III.....	23
METODOLOGI.....	23
3.1 Data.....	23
3.1.1 Sumber dan Cakupan Data.....	23
3.1.2 Variabel Penelitian.....	24
3.1.3 Preprocessing Data	24
3.2 Metode	25
3.2.1 Kerangka Komparatif Enam Algoritma.....	25
3.2.2 Implementasi Isolation Forest.....	25
3.2.3 Implementasi Local Outlier Factor	26
3.2.4 Implementasi Autoencoder Neural Network.....	26
3.2.5 Implementasi One-Class SVM.....	27
3.2.6 Implementasi PCA-based Anomaly Detection	27
3.2.7 Implementasi DBSCAN.....	28

3.3 Alur Penelitian (Research Workflow)	28
3.4 Matriks Evaluasi.....	29
3.4.1 Area Under the ROC Curve (AUC-ROC).....	29
3.4.2 F1-Score dan Precision-Recall Curve	30
3.4.3 Silhouette Index untuk Evaluasi DBSCAN	30
3.4.4 Davies-Bouldin Index (DBI).....	31
3.5 Target Penelitian	31
DAFTAR PUSTAKA.....	32

BAB I

PENDAHULUAN

1.1 Latar Belakang

Krisis ekonomi merupakan salah satu fenomena paling destruktif dalam sistem perekonomian global, yang dampaknya tidak hanya dirasakan oleh negara yang mengalaminya secara langsung, tetapi juga menjalar secara sistemis ke seluruh jaringan ekonomi dunia. Sejarah mencatat berbagai episode krisis besar yang meninggalkan dampak mendalam, seperti Krisis Keuangan Asia 1997–1998 yang mengguncang Asia Tenggara, Krisis Dotcom 2000–2001 yang menghapus triliunan dolar nilai pasar, Krisis Keuangan Global 2008–2009 yang dipicu oleh runtuhnya pasar subprime mortgage di Amerika Serikat, serta dampak ekonomi dari Pandemi COVID-19 2020 yang menyebabkan kontraksi ekonomi global sebesar 3,3%. Rangkaian peristiwa ini menunjukkan bahwa sistem ekonomi modern bersifat kompleks, saling terhubung, dan rentan terhadap kegagalan sistemik yang tidak selalu dapat diprediksi melalui pendekatan konvensional.

Dalam konteks tersebut, pengembangan Early Warning System (EWS) menjadi semakin penting sebagai alat untuk mendeteksi sinyal awal sebelum krisis terjadi. EWS dirancang untuk mengidentifikasi anomali dalam indikator makroekonomi sehingga memberikan waktu bagi pembuat kebijakan untuk melakukan langkah preventif. Konsep ini telah lama menjadi perhatian akademisi dan institusi internasional seperti International Monetary Fund dan World Bank. Penelitian klasik oleh Graciela Kaminsky, Saul Lizondo, dan Carmen Reinhart (1997) menunjukkan bahwa variabel seperti ekspor, output, harga aset, dan cadangan internasional memiliki kemampuan dalam memberikan sinyal krisis. Studi tersebut menjadi fondasi bagi pengembangan EWS modern yang terus berkembang hingga saat ini.

Namun demikian, pendekatan konvensional dalam membangun EWS masih memiliki keterbatasan. Model statistik seperti logit dan probit mengandalkan asumsi distribusi tertentu serta hubungan linier antar variabel, padahal data makroekonomi bersifat multidimensional, non-linear, dan sering mengandung noise serta missing values. Oleh karena itu, pendekatan machine learning, khususnya deteksi anomali secara unsupervised, menjadi alternatif yang lebih adaptif. Studi oleh Tuomas Holopainen dan Peter Sarlin (2016) menunjukkan bahwa metode machine learning mampu memberikan performa yang lebih baik dibandingkan pendekatan tradisional dalam konteks

EWS. Selain itu, deteksi anomali dalam data makroekonomi memiliki karakteristik khusus, di mana anomali tidak selalu berupa titik ekstrem, tetapi dapat berupa pola kontekstual yang hanya bermakna dalam dimensi waktu dan perbandingan antar negara.

Dataset yang digunakan dalam penelitian ini bersumber dari World Bank Global Economic Monitor dan dikombinasikan dengan data krisis historis dari International Monetary Fund untuk keperluan validasi. Dataset mencakup 49 negara dalam periode 1990–2024 dengan total 1.715 observasi setelah preprocessing. Pemilihan negara dilakukan secara purposive dengan mempertimbangkan dua aspek utama, yaitu kelengkapan data dan representasi struktur ekonomi global. Dari sisi kualitas data, hanya negara dengan ketersediaan indikator yang relatif lengkap dan konsisten yang dipilih, guna meminimalkan bias akibat missing values. Dari sisi representasi, pemilihan negara dirancang untuk mencakup spektrum ekonomi global secara seimbang, meliputi negara maju yang tergabung dalam G7 (Amerika Serikat, Inggris, Jerman, Prancis, Italia, Jepang, Kanada), emerging economies seperti BRICS (Brasil, Rusia, India, Tiongkok, Afrika Selatan), serta negara berkembang dari kawasan ASEAN (Indonesia, Thailand, Malaysia, Filipina, Vietnam, Singapura). Selain itu, penelitian ini juga memasukkan negara dari Asia lainnya (Korea Selatan, Pakistan, Bangladesh, Sri Lanka), Amerika Latin (Meksiko, Argentina, Kolombia, Chili, Peru), Timur Tengah dan Afrika (Arab Saudi, Turki, Mesir, Nigeria, Kenya, Uni Emirat Arab), Eropa non-G7 (Spanyol, Belanda, Swedia, Norwegia, Polandia, Yunani, Portugal, Irlandia, Swiss, Austria, Belgia, Ceko, Hungaria, Rumania), serta Oseania (Australia dan Selandia Baru). Pendekatan ini memastikan bahwa dataset tidak hanya mencerminkan variasi geografis, tetapi juga heterogenitas tingkat pembangunan ekonomi, struktur industri, serta kerentanan terhadap krisis.

Penelitian ini mengusung pendekatan unsupervised anomaly detection yang tidak bergantung pada label krisis dalam proses pelatihan model, sehingga lebih fleksibel dibandingkan pendekatan supervised yang membutuhkan data krisis historis yang lengkap dan konsisten. Dibandingkan dengan analisis univariat atau sistem berbasis threshold statis, pendekatan multivariat berbasis machine learning dalam penelitian ini mampu menangkap interaksi kompleks antar indikator dan menyesuaikan diri terhadap heterogenitas antar negara. Enam algoritma yang digunakan, yaitu Isolation Forest, Local Outlier Factor (LOF), Autoencoder, One-Class SVM, PCA-based anomaly detection, dan DBSCAN, merepresentasikan berbagai pendekatan dalam deteksi anomali, mulai dari berbasis isolasi, kepadatan, representasi neural network, hingga clustering. Analisis

komparatif antar metode ini diharapkan tidak hanya mampu mengidentifikasi pola anomali yang berkaitan dengan krisis ekonomi, tetapi juga memberikan kontribusi sebagai dasar pengembangan sistem peringatan dini (EWS) yang lebih adaptif dan berbasis data di masa depan.

1.2 Identifikasi Masalah

1. Krisis ekonomi global yang berulang mulai dari Krisis Asia (1997-1998), Krisis Keuangan Global (2008-2009), hingga guncangan ekonomi pandemi COVID-19 (2020) menunjukkan bahwa sistem pemantauan indikator makroekonomi konvensional belum mampu mendeteksi sinyal-sinyal awal kerentanan secara akurat dan tepat waktu, sehingga peluang tindakan preventif yang bermakna seringkali terlewatkan.
2. Pendekatan EWS berbasis metode statistik tradisional (logit, probit, signal extraction) dan *supervised learning* memiliki keterbatasan inheren berupa ketergantungan pada asumsi distribusi yang kaku, relasi linier, dan kebutuhan akan data label krisis yang lengkap dan konsisten persyaratan yang sangat sulit dipenuhi dalam konteks data makroekonomi global yang bersifat heterogen, multidimensional, dan mengandung *missing values substansial*.
3. Belum terdapat kajian komparatif yang sistematis dan menyeluruh mengenai efektivitas algoritma *unsupervised anomaly detection* Isolation Forest, Local Outlier Factor, Autoencoder, One-Class SVM, PCA-based detection, dan DBSCAN dalam konteks spesifik deteksi anomali indikator makroekonomi multivariat dari perspektif lintas-negara dan lintas-waktu, sehingga pilihan metode yang paling optimal untuk keperluan EWS krisis ekonomi belum teridentifikasi.
4. Kurangnya peta distribusi spasial dan temporal anomali makroekonomi global yang dibangun berdasarkan metodologi yang tervalidasi menghambat upaya pemahaman pola historis krisis ekonomi secara komprehensif, yang merupakan prasyarat penting bagi perumusan kebijakan ekonomi dan keuangan yang antisipatif dan berbasis bukti.

1.3 Tujuan

1. Melakukan deteksi dan segmentasi anomali pada data indikator makroekonomi global yang mencakup 16 variabel dari 49 negara dalam rentang 1990-2024, menggunakan pendekatan *unsupervised anomaly detection* yang tidak bergantung pada label krisis historis.
2. Membandingkan performa enam algoritma *unsupervised anomaly detection* Isolation Forest, Local Outlier Factor (LOF), Autoencoder Neural Network, One-Class Support Vector Machine (OCSVM), PCA-based Anomaly Detection, dan DBSCAN guna mengidentifikasi metode yang paling optimal, stabil, dan akurat dalam mendeteksi anomali pada data makroekonomi multivariat.
3. Menghasilkan sistem Early Warning System (EWS) berbasis deteksi anomali yang mampu mengidentifikasi negara-negara dan periode-periode yang menunjukkan pola makroekonomi menyimpang secara signifikan dari kondisi normal, yang berpotensi mengindikasikan kerentanan pra-krisis.
4. Memvalidasi hasil deteksi anomali dengan merujuk pada data krisis historis yang terdokumentasi, sehingga menghasilkan evidensi empiris mengenai efektivitas pendekatan *unsupervised anomaly detection* sebagai instrumen EWS krisis ekonomi yang praktis dan dapat direplikasi.

BAB II

KAJIAN LITERATUR

2.1 Konsep Definisi

2.1.1 Konsep Dasar Krisis Ekonomi dan Early Warning System

2.1.1.1 Krisis Ekonomi dan Tipologinya

Krisis ekonomi secara luas didefinisikan sebagai kondisi di mana perekonomian suatu negara mengalami penurunan tajam dan berkelanjutan dalam aktivitas ekonominya, yang ditandai oleh kontraksi output, lonjakan pengangguran, keruntuhan sistem keuangan, atau kombinasi ketiganya. Dalam literatur ekonomi, krisis diklasifikasikan ke dalam beberapa tipologi berdasarkan sumbernya: (a) krisis mata uang (*currency crisis*), yaitu depresiasi nilai tukar yang tajam dan cepat atau serangan spekulatif terhadap cadangan devisa, sebagaimana yang terjadi di Thailand pada Juli 1997 sebagai pemicu Krisis Asia; (b) krisis perbankan (*banking crisis*), yaitu kondisi di mana bank-bank mengalami tekanan likuiditas atau solvabilitas yang cukup parah sehingga membutuhkan intervensi pemerintah, seperti yang terjadi di Amerika Serikat pada 2008; (c) krisis utang (*debt crisis*), yaitu ketidakmampuan pemerintah atau sektor swasta untuk memenuhi kewajiban utangnya, seperti yang dialami beberapa negara Eropa dalam krisis zona euro 2010-2012; dan (d) krisis sistemik yang merupakan kombinasi dari beberapa tipologi di atas yang saling memperkuat dan menyebar melalui mekanisme *contagion* antar-negara.

2.1.1.2 Early Warning System (EWS)

Early Warning System (EWS) dalam konteks makro ekonomi merupakan sistem pemantauan yang dirancang untuk mendeteksi sinyal-sinyal peringatan dini mengenai meningkatnya kerentanan perekonomian terhadap krisis, sehingga memberikan kesempatan bagi para pemangku kebijakan untuk mengambil tindakan pencegahan sebelum krisis benar-benar terjadi. Konsep EWS makroekonomi pertama kali dikembangkan secara sistematis oleh Kaminsky, Lizondo, dan Reinhart (1997) melalui pendekatan 'signal extraction', di mana setiap indikator dipantau secara individual dan dinyatakan memberikan 'sinyal' ketika nilainya melampaui *threshold* tertentu. Pendekatan ini, meskipun intuitif dan interpretatif, memiliki keterbatasan dalam menangkap interaksi multivariat antar-indikator. Generasi kedua EWS menggunakan model probabilistik seperti logit dan probit untuk memodelkan probabilitas krisis sebagai fungsi dari beberapa indikator secara simultan. Generasi terbaru EWS, yang menjadi fokus penelitian ini, menggunakan algoritma *machine learning* yang mampu mendeteksi pola non-linier

dan interaksi kompleks antara variabel tanpa memerlukan spesifikasi model yang kaku, sebagaimana diulas secara komprehensif oleh Holopainen dan Sarlin (2016).

2.1.1.3 Indikator Makroekonomi sebagai Sinyal EWS

Indikator makroekonomi yang digunakan dalam penelitian ini mencakup 16 variabel yang dipilih berdasarkan relevansinya sebagai sinyal potensial krisis ekonomi menurut literatur EWS. GDP Growth dan GDP Per Capita Growth mengukur dinamika pertumbuhan ekonomi riil dan mencerminkan kondisi siklus bisnis; perlambatan atau kontraksi yang signifikan pada variabel ini seringkali mendahului atau menyertai periode krisis. Inflation CPI mengukur tekanan harga konsumen; inflasi yang tinggi dan tidak stabil dapat mengindikasikan ketidakstabilan makroekonomi. Total *Reserves* mencerminkan kemampuan sebuah negara untuk mempertahankan nilai tukarnya dan memenuhi kewajiban luar negerinya jangka pendek; Kaminsky et al. (1997) menemukan bahwa rasio M2 terhadap cadangan devisa merupakan salah satu prediktor krisis mata uang terkuat. Unemployment Rate mencerminkan kondisi pasar tenaga kerja dan seringkali meningkat tajam pasca-krisis. Current Account to GDP dan Trade to GDP mengukur posisi eksternal perekonomian. FDI Inflows to GDP, Exports to GDP, Imports to GDP, dan Exchange Rate melengkapi gambaran keterbukaan dan kerentanan eksternal. Gross Savings to GDP dan Investment to GDP mencerminkan dinamika tabungan dan investasi domestik. Manufacturing Value Added mencerminkan produktivitas sektor riil.

2.1.2 Anomali dan Deteksi Anomali

2.1.2.1 Definisi dan Tipologi Anomali

Anomali, atau yang dalam literatur *data mining* juga disebut sebagai *outlier*, didefinisikan sebagai observasi atau pola data yang secara signifikan menyimpang dari perilaku yang diharapkan berdasarkan mayoritas data. Breunig et al. (2000) dalam makalah fondasi LOF mendefinisikan outlier sebagai 'objek-objek yang jarang ditemukan dan berbeda secara signifikan dari sisa datanya.' Definisi ini menekankan bahwa sifat anomali bersifat relatif terhadap konteks lokal data di sekitarnya, bukan hanya terhadap statistik global. Dalam literatur deteksi anomali, terdapat tiga tipologi utama anomali yang relevan dengan konteks data makroekonomi: (1) *Point anomaly*, yaitu observasi tunggal yang nilainya sangat berbeda dari observasi lainnya, misalnya lonjakan inflasi yang sangat tajam dalam satu tahun tertentu di suatu negara; (2) *Contextual anomaly* (atau conditional anomaly), yaitu observasi yang bersifat anomali hanya dalam konteks tertentu, misalnya tingkat pengangguran 5% yang merupakan anomali untuk Jepang tetapi normal untuk

Amerika Serikat; dan (3) *Collective anomaly*, yaitu sekumpulan observasi yang secara individual mungkin tidak anomali, tetapi ketika dilihat secara bersama-sama membentuk pola yang menyimpang, misalnya serangkaian pertumbuhan kredit yang tinggi bersamaan dengan depresiasi nilai tukar yang stabil sebelum krisis perbankan.

2.1.2.2 Anomali dalam Konteks Data Deret Waktu Makroekonomi

Data makroekonomi yang digunakan dalam penelitian ini memiliki karakteristik panel data, yaitu kombinasi dimensi lintas negara (cross-sectional) dan dimensi waktu (time series). Karakteristik ini menambah kompleksitas dalam deteksi anomali karena 'normalitas' perlu didefinisikan secara berbeda untuk setiap negara dan setiap periode waktu. Jain, Bajpai, dan Pamula (2022) dalam penelitian mereka mengenai *modified DBSCAN* untuk data deret waktu dengan *seasonality* menunjukkan bahwa algoritma *clustering* konvensional dapat gagal mendeteksi *local anomaly* dalam data yang memiliki pola musiman atau tren, dan mengusulkan modifikasi yang mempertimbangkan komponen temporal. Implikasi untuk penelitian ini adalah bahwa algoritma-algoritma yang digunakan harus mampu menangkap tidak hanya anomali global (yang jelas menyimpang dari rata-rata keseluruhan dataset) tetapi juga anomali kontekstual yang bersifat lokal, yakni observasi yang anomali relatif terhadap tetangga temporalnya atau terhadap negara-negara dengan karakteristik ekonomi serupa.

2.1.3 Metode Deteksi Anomali Unsupervised

2.1.3.1 Isolation Forest

Isolation Forest (iForest) merupakan algoritma deteksi anomali yang diperkenalkan oleh Liu, Ting, dan Zhou (2008) dalam makalah seminal mereka yang dipresentasikan pada IEEE International Conference on Data Mining. Berbeda dari mayoritas metode deteksi anomali yang terlebih dahulu membangun profil 'normalitas' dan kemudian mengidentifikasi instansi yang tidak sesuai dengan profil tersebut, Isolation Forest mengadopsi pendekatan yang secara fundamental berbeda: alih-alih memprofilkan normalitas, iForest secara langsung mengisolasi anomali berdasarkan dua sifat kuantitatif yang dimilikinya, yaitu (i) anomali adalah minoritas yang terdiri dari sangat sedikit instansi, dan (ii) nilai atribut anomali sangat berbeda dari instansi normal. Kedua sifat ini membuat anomali lebih mudah diisolasi dibandingkan titik-titik normal.

Mekanisme kerja Isolation Forest didasarkan pada struktur Isolation Tree (iTree). Sebuah iTree dibangun secara rekursif dengan cara mempartisi data: pada setiap node, sebuah fitur dipilih secara acak dari seluruh fitur yang tersedia, kemudian sebuah nilai split dipilih secara acak dari

rentang nilai fitur tersebut. Proses partisi berlanjut hingga setiap titik data terisolasi secara sempurna (berada dalam partisi yang hanya berisi satu titik) atau hingga kedalaman tree mencapai batas yang ditetapkan. Karena anomali dengan nilai atribut yang ekstrem dan berbeda cenderung membutuhkan lebih sedikit partisi untuk diisolasi, *path length* dari *root* ke *external node* yang mengandung anomali akan lebih pendek dibandingkan *path length* untuk titik normal yang dikelilingi oleh titik-titik serupa. *Anomaly score* untuk setiap titik dihitung sebagai fungsi dari rata-rata *path length* lintas seluruh iTree dalam ensemble iForest.

Secara matematis, anomaly score $s(x, n)$ untuk titik x dalam dataset berukuran n didefinisikan sebagai:

$$s(x, n) = 2^{-\frac{\mathbb{E}[h(x)]}{c(n)}}$$

di mana $\mathbb{E}[h(x)]$ adalah ekspektasi *path length* titik x di seluruh iTree dalam ensemble, dan

$$c(n) = 2H(n-1) - \frac{2(n-1)}{n}$$

adalah rata-rata *path length* dari Unsuccessful Search dalam Binary Search Tree dengan n titik, dengan $H(i)$ adalah harmonic number. Nilai s mendekati 1 mengindikasikan anomali kuat, nilai s jauh di bawah 0,5 mengindikasikan titik normal, dan nilai s di sekitar 0,5 mengindikasikan tidak ada anomali yang distinct. Parameter utama iForest hanyalah dua: jumlah iTree (t , biasanya 100) dan sub-sampling size (ψ , biasanya 256), menjadikannya algoritma yang sangat efisien secara komputasi dengan kompleksitas waktu linear $O(n)$.

Keunggulan utama Isolation Forest dalam konteks penelitian ini adalah kemampuannya menangani data berdimensi tinggi, tidak memerlukan asumsi distribusi data, memiliki kompleksitas komputasi linear yang sangat efisien bahkan untuk dataset berskala besar, dan tidak memerlukan parameter yang sulit dikalibrasi. Al Farizi, Hidayah, dan Rizal (2021) dalam *systematic literature review* mereka terhadap 17 studi mengenai Isolation Forest menegaskan bahwa iForest secara konsisten mengungguli LOF, OCSVM, dan GMM dalam hal akurasi dan kecepatan komputasi pada berbagai dataset *benchmark*. Kelemahan utamanya adalah sensitivitas terhadap ‘masking effect’ di mana kluster anomali yang padat dapat ter-misklasifikasi sebagai normal, dan ‘swamping effect’ di mana titik normal yang berada di area *sparse* dapat dikira anomali. Xu et al. (2019) mengusulkan SA-iForest yang menggunakan *simulated annealing* untuk mengatasi kelemahan ini dengan menyeleksi iTree yang berkinerja tinggi dan berbeda satu sama

lain. Dalam penelitian ini, iForest akan diterapkan dengan parameter kontaminasi yang dikalibrasi terhadap frekuensi historis krisis ekonomi dalam dataset.

Relevansi iForest untuk data makroekonomi telah didemonstrasikan secara implisit melalui aplikasinya pada data keuangan dan ekonomi. Susto, Beghi, dan McLoone (2017) menggunakan iForest untuk monitoring anomali dalam proses manufaktur semikonduktor dan menunjukkan keunggulannya dibandingkan *univariate control chart*. Li et al. (2021) mengembangkan *Similarity-Measured Isolation Forest (SM-iForest)* yang meningkatkan *robustness* iForest terhadap data monitoring mesin dengan menambahkan tahap pengukuran kesamaan relatif segmen-segmen yang teridentifikasi sebagai potensial anomali. Ding dan Fei (2013) mengembangkan iForestASD yang mengadaptasi iForest untuk streaming data menggunakan *sliding window*, yang relevan untuk pemantauan indikator makroekonomi secara *real-time*. Dalam penelitian ini, iForest menjadi *baseline* utama karena kombinasi uniknya antara efisiensi komputasi, kemampuan multivariat, dan tidak bergantung pada asumsi distribusi.

2.1.3.2 Local Outlier Factor (LOF)

Local Outlier Factor (LOF) merupakan algoritma deteksi *outlier* berbasis kepadatan (density-based) yang diperkenalkan oleh Breunig, Kriegel, Ng, dan Sander (2000) dalam makalah berpengaruh mereka yang dipublikasikan di Proceedings of ACM SIGMOD. Kontribusi utama LOF terhadap literatur deteksi anomali adalah konsepnya mengenai 'derajat menjadi outlier' (degree of being an outlier) yang bersifat lokal dan kontinu, bukan biner. Berbeda dari pendekatan berbasis jarak global yang mendefinisikan outlier semata-mata berdasarkan jarak terhadap seluruh dataset, LOF mengevaluasi keanehan setiap titik relatif terhadap kepadatan lokal tetangga-tetangganya yang terdekat. Sebuah titik dianggap anomali jika kepadatan lokalnya jauh lebih rendah dibandingkan kepadatan lokal tetangga-tetangganya, artinya titik tersebut berada di area yang relatif sepi sementara tetangga-tetangganya berkerumun rapat.

Secara formal, LOF untuk titik p didefinisikan melalui serangkaian konsep:

1. k -distance(p): jarak dari p ke titik tetangga terjauhnya dalam k -nearest neighborhood.
2. k -distance neighborhood $\mathcal{N}_k(p)$: himpunan titik-titik yang jaraknya dari p tidak lebih dari k -distance(p).
3. Reachability distance:

$$\text{reach-dist}_k(p, o) = \max\{k\text{-distance}(o), d(p, o)\}$$

merupakan modifikasi terhadap jarak Euclidean yang memperhalus kepadatan di sekitar titik-titik padat.

4. Local reachability density:

$$\text{lrd}_k(p) = \left(\frac{\sum_{o \in \mathcal{N}_k(p)} \text{reach-dist}_k(p, o)}{|\mathcal{N}_k(p)|} \right)^{-1}$$

kebalikan dari rata-rata reachability distance p terhadap tetangga-tetangganya, mengukur seberapa ‘terjangkau’ p dari tetangganya.

5. Local Outlier Factor:

$$\text{LOF}_k(p) = \frac{\sum_{o \in \mathcal{N}_k(p)} \frac{\text{lrd}_k(o)}{\text{lrd}_k(p)}}{|\mathcal{N}_k(p)|}$$

rasio antara rata-rata kepadatan lokal tetangga-tetangga p dibandingkan kepadatan lokal p sendiri. $\text{LOF} \approx 1$ mengindikasikan p berada dalam kluster yang padat (normal), sedangkan $\text{LOF} \gg 1$ mengindikasikan p adalah outlier.

Keunggulan fundamental LOF adalah kemampuannya mendeteksi *local outlier* yang tidak dapat diidentifikasi oleh metode global, seperti titik yang berada di area dataset yang secara umum jarang tetapi lebih jarang lagi dibandingkan tetangganya yang terdekat. Breunig et al. (2000) memberikan analisis formal yang menunjukkan bahwa untuk titik-titik dalam kluster, LOF-nya mendekati 1, sementara untuk outlier sejati, batas bawah dan atas LOF dapat dihitung sebagai fungsi dari kepadatan relatif kluster-kluster di sekitarnya. Parameter utama LOF adalah MinPts (k), yang menentukan ukuran *neighborhood local*. LOF relatif *robust* terhadap pilihan MinPts dalam rentang yang wajar (10–50 untuk dataset berukuran sedang). Kelemahan utama LOF adalah kompleksitas komputasi $O(n^2)$ yang menjadi *bottleneck* untuk dataset sangat besar, serta sensitivitasnya terhadap dimensionalitas tinggi karena fenomena ‘curse of dimensionality’ yang menyebabkan jarak antar titik menjadi homogen di ruang berdimensi sangat tinggi.

Auskalnis, Paulauskas, dan Baskys (2018) menerapkan LOF untuk deteksi anomali dalam jaringan komputer menggunakan dataset NSL-KDD dan menunjukkan bahwa LOF efektif mendeteksi serangan jaringan yang tidak diketahui sebelumnya (zero-day attacks) ketika hanya data normal yang tersedia untuk pelatihan model. Ini relevan secara konseptual dengan aplikasi makroekonomi di mana 'normalitas' makroekonomi lebih mudah dikarakterisasi dibandingkan 'krisis'. Budiarto, Permanasari, dan Fauziati (2019) membandingkan LOF dengan K-Means dan OCSVM untuk deteksi anomali pada data penggunaan obat di rumah sakit dan menemukan bahwa OCSVM mengungguli LOF, yang menunjukkan bahwa pemilihan algoritma optimal bergantung pada karakteristik data spesifik justifikasi kuat bagi pendekatan komparatif dalam penelitian ini.

Dalam konteks data makroekonomi multivariat panel, LOF akan diterapkan setelah standardisasi *Z-score* untuk memastikan semua variabel berada pada skala yang setara. Nilai MinPts akan dikalibrasi melalui *grid search* dalam rentang 5-50. Relevansi LOF untuk EWS makroekonomi terletak pada kemampuannya mengidentifikasi episode-episode historis di mana suatu perekonomian mulai berperilaku 'berbeda dari biasanya' secara lokal dalam ruang fitur, yang merupakan karakteristik kondisi pra-krisis yang tidak selalu terdeteksi oleh metode global.

2.1.3.3 Autoencoder Neural Network

Autoencoder merupakan arsitektur jaringan saraf tiruan (artificial neural network) yang dirancang untuk mempelajari representasi kompresi (encoding) dari data input dengan cara melatih jaringan untuk merekonstruksi input-nya sendiri melalui *bottleneck layer* berdimensi lebih rendah. Arsitektur autoencoder terdiri dari dua komponen utama: *encoder* yang memetakan input $\mathbf{x}$ ke representasi laten $\mathbf{z} = f_{\theta}(\mathbf{x})$ berdimensi lebih rendah, dan *decoder* yang mencoba merekonstruksi input asal dari representasi laten tersebut: $\hat{\mathbf{x}} = g_{\phi}(\mathbf{z})$. Model dilatih dengan meminimalkan *reconstruction error*, yang paling umum diukur menggunakan Mean Squared Error (MSE):

$$\mathcal{L} = \|\mathbf{x} - \hat{\mathbf{x}}\|^2$$

Ide menggunakan autoencoder untuk deteksi anomali didasarkan pada premis bahwa model yang dilatih secara eksklusif pada data normal akan menjadi sangat mahir merekonstruksi data normal, tetapi buruk dalam merekonstruksi anomali karena fitur-fitur anomali tidak direpresentasikan

dengan baik dalam ruang laten yang dibentuk oleh distribusi data normal. Sehingga, titik data dengan *reconstruction error* tinggi dapat diklasifikasikan sebagai anomali.

Sakurada dan Yairi (2014) dalam penelitian fondasi yang dipresentasikan di MLSDA Workshop, ACM, membandingkan autoencoder dengan PCA linier dan Kernel PCA untuk deteksi anomali pada telemetri pesawat ruang angkasa. Mereka menunjukkan bahwa autoencoder mampu mendeteksi *anomaly subtle* yang gagal diidentifikasi oleh PCA linier, karena kemampuan non-linier autoencoder dalam mengkompresi dan merekonstruksi manifold kompleks dari data normal. Temuan ini sangat relevan untuk data makroekonomi yang mengandung hubungan non-linier kuat antar-variabel, seperti hubungan non-linier antara pertumbuhan PDB dan inflasi dalam konteks berbagai kondisi ekonomi. Autoencoder juga menunjukkan bahwa perluasan ke *denoising autoencoder* yang dilatih untuk merekonstruksi data bersih dari input yang sengaja diberi *noise* lebih lanjut meningkatkan kemampuan deteksi anomali dengan membuat representasi laten lebih robust.

Kim et al. (2023) mengembangkan pendekatan *active anomaly detection* berbasis *deep one-class classification* yang mengintegrasikan autoencoder dengan framework *active learning*, menunjukkan bahwa strategi pemilihan sampel yang cerdas dapat meningkatkan efisiensi pelatihan model *anomaly detection* ketika label tersedia secara terbatas. Bao, Yue, dan Rao (2017) menggunakan *stacked autoencoder* dalam kombinasi dengan LSTM untuk prediksi deret waktu keuangan, menunjukkan bahwa representasi hierarkis yang dipelajari oleh *stacked autoencoder* mampu menangkap fitur-fitur temporal dalam data keuangan yang tidak tertangkap oleh representasi fitur manual.

Dalam penelitian ini, autoencoder untuk deteksi anomali makroekonomi akan dirancang dengan arsitektur simetris: *input layer* dengan 16 neuron (sesuai jumlah indikator makroekonomi), *encoder* dengan *hidden layers* 64-32 neuron dan *bottleneck layer* 8 neuron (kompresi dimensi 50%), serta *decoder* yang merupakan *mirror* dari *encoder*. Fungsi aktivasi ReLU digunakan pada *hidden layers* dan fungsi aktivasi linier pada *output layer*. Model dilatih menggunakan *optimizer Adam* dengan *learning rate* 0.001, *batch size* 32, dan 100 *epoch* dengan *early stopping* berdasarkan *validation loss*. *Threshold* anomali ditentukan berdasarkan persentil ke-95 dari distribusi *reconstruction error* pada data latih. Keunggulan *autoencoder* dalam konteks ini adalah kemampuannya menangkap pola non-linier kompleks dalam interaksi antar-indikator

makroekonomi, yang merupakan karakteristik penting karena kondisi pra-krisis seringkali ditandai oleh kombinasi antar-indikator yang tidak normal, bukan hanya nilai individual yang ekstrem.

2.1.3.4 One-Class Support Vector Machine (OCSVM)

One-Class Support Vector Machine (OCSVM), yang juga dikenal sebagai Support Vector Data Description (SVDD), merupakan ekstensi dari algoritma Support Vector Machine (SVM) untuk skenario one-class classification, di mana model dilatih hanya menggunakan data dari satu kelas (dalam hal ini, kondisi makroekonomi normal) untuk kemudian mengidentifikasi data baru yang tidak termasuk dalam distribusi kelas tersebut. Dikembangkan secara independen oleh Schölkopf et al. (2001) dan Tax dan Duin (2004), OCSVM bekerja dengan menemukan hyperplane dalam ruang fitur kernel yang memisahkan data latih dari titik asal dengan margin yang semaksimal mungkin, sehingga secara efektif menggambar batas keputusan di sekitar data normal.

Secara formal, OCSVM menyelesaikan masalah optimasi berikut:

$$\min_{\mathbf{w}, \rho, \xi} \quad \frac{1}{2} \|\mathbf{w}\|^2 - \rho + \frac{1}{vn} \sum_{i=1}^n \xi_i$$

dengan batasan:

$$\mathbf{w} \cdot \phi(\mathbf{x}_i) \geq \rho - \xi_i \quad \text{dan} \quad \xi_i \geq 0$$

di mana $\phi(\mathbf{x})$ adalah fungsi kernel yang memetakan input ke ruang fitur berdimensi tinggi, $\mathbf{w}$ adalah vektor normal hyperplane pemisah, ρ adalah offset, ξ_i adalah slack variable, dan v adalah parameter yang mengontrol trade-off antara fraction anomali yang diizinkan dan ukuran margin. v mendekati 0 menghasilkan batas yang lebih ketat dengan lebih sedikit anomali yang terdeteksi, sementara v mendekati 1 menghasilkan batas yang lebih longgar. Fungsi keputusan untuk titik baru $\mathbf{x}$ adalah:

$$f(\mathbf{x}) = \text{sign}(\mathbf{w} \cdot \phi(\mathbf{x}) - \rho)$$

di mana $f(\mathbf{x}) = +1$ mengindikasikan normal dan $f(\mathbf{x}) = -1$ mengindikasikan anomali. Kernel yang paling umum digunakan adalah Radial Basis Function (RBF):

$$K(\mathbf{x}, \mathbf{y}) = \exp(-\gamma \|\mathbf{x} - \mathbf{y}\|^2)$$

Qiao et al. (2021) mengembangkan bentuk baru OCSVM untuk data berdimensi tinggi dalam konteks IoT sensing data, di mana mereka menggunakan Deep Belief Network untuk kompresi dimensi sebelum OCSVM, mengatasi bottleneck komputasi OCSVM pada data berdimensi sangat tinggi. Pendekatan dua-tahap ini relevan untuk dataset makroekonomi multivariat di mana beberapa variabel mungkin berkorelasi tinggi dan dapat dikompresi tanpa kehilangan informasi yang signifikan. Budiarto et al. (2019) membandingkan OCSVM, LOF, dan K-Means pada dataset penggunaan obat dan menemukan bahwa OCSVM mengungguli kedua algoritma lainnya dalam terms of accuracy dan execution time, menunjukkan efisiensi OCSVM pada data berukuran sedang.

Keunggulan OCSVM dalam konteks penelitian ini adalah kemampuannya menangkap bentuk boundary keputusan yang arbitrarily complex melalui kernel trick, robustness terhadap outlier dalam data latih (karena beberapa support vectors dapat menjadi outlier), dan adanya parameter ν yang memberikan kontrol eksplisit atas contamination rate yang diharapkan. Kelemahan utamanya adalah sensitivitas terhadap pilihan kernel dan parameter γ , serta kompleksitas komputasi yang menjadi $O(n^2)$ hingga $O(n^3)$ tergantung implementasi, yang dapat menjadi bottleneck untuk dataset berukuran besar. Dalam penelitian ini, OCSVM akan menggunakan kernel RBF dengan parameter ν dan γ yang dioptimalkan melalui grid search. Preprocessing menggunakan StandardScaler menjadi sangat penting karena OCSVM sensitif terhadap skala fitur.

2.1.3.5 PCA-based Anomaly Detection

Principal Component Analysis (PCA) sebagai metode deteksi anomali bekerja melalui prinsip bahwa data normal cenderung berada pada atau dekat manifold linear yang dibentuk oleh komponen-komponen utama dengan varians tinggi, sementara anomali cenderung memiliki komponen signifikan yang jatuh di luar manifold tersebut atau di sepanjang komponen-komponen minor dengan varians rendah yang merepresentasikan 'noise'. Pendekatan deteksi anomali berbasis PCA melibatkan: (1) Proyeksi data ke ruang komponen utama (PC space) menggunakan matriks eigenvector; (2) Rekonstruksi data kembali ke ruang asli menggunakan hanya k komponen utama pertama yang menjelaskan sebagian besar varians; (3) Pengukuran reconstruction error (Squared Prediction Error, SPE, atau Q-statistic) sebagai ukuran anomali titik dengan SPE tinggi mengindikasikan bahwa mereka tidak dapat direpresentasikan dengan baik oleh k komponen

utama pertama, yang merupakan indikasi anomali; (4) Hotelling's T-squared statistic untuk mengukur anomali dalam ruang PC tereduksi.

Yousfani et al. (2025) menggunakan PCA sebagai inti dari Financial Stress Index (FSI) yang mereka bangun untuk Pakistan, mengkonsolidasikan berbagai indikator tekanan keuangan termasuk tekanan sektor perbankan, tekanan nilai tukar, volatilitas pasar saham, spread pasar uang, eksposur utang eksternal, dan kondisi trade finance menjadi satu ukuran tunggal yang interpretatif. Studi ini menemukan bahwa FSI berbasis PCA berhasil mengidentifikasi episode krisis keuangan utama Pakistan dengan jelas, termasuk GFC 2008, pandemi COVID-19, dan gangguan politik domestik. Lebih lanjut, studi ini menunjukkan bahwa komponen pertama PCA yang menjelaskan varians terbesar sesuai dengan dimensi 'tekanan sistemik' yang merupakan indikator leading terhadap perlambatan ekonomi. Keunggulan PCA dalam konteks EWS makroekonomi adalah interpretabilitasnya yang tinggi komponen utama dapat diinterpretasikan sebagai 'indeks tekanan makroekonomi komposit' serta kemampuannya mereduksi multikolinearitas yang umum dalam data makroekonomi.

Hong, Wu, Xu, dan Xiong (2022) mengaplikasikan kombinasi PCA dan decision tree untuk early warning risiko keuangan perusahaan dan menemukan bahwa PCA meningkatkan akurasi klasifikasi decision tree hingga 1,6% dibandingkan baseline. Dalam penelitian ini, PCA-based anomaly detection akan diimplementasikan dengan menentukan jumlah komponen utama yang dipertahankan berdasarkan kriteria explained variance ($\geq 95\%$), menghitung SPE dan T^2 statistik untuk setiap observasi, dan menggunakan threshold berbasis UCL (Upper Control Limit) dari distribusi chi-squared untuk menentukan apakah suatu observasi merupakan anomali. PCA memiliki keunggulan komputasi yang signifikan karena kompleksitasnya linear dalam jumlah observasi, menjadikannya kandidat yang tepat untuk implementasi real-time dalam sistem pemantauan EWS.

2.1.3.6 DBSCAN (Density-Based Spatial Clustering of Applications with Noise)

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) merupakan algoritma clustering berbasis kepadatan yang diperkenalkan oleh Ester, Kriegel, Sander, dan Xu (1996) dalam makalah yang mendapatkan SIGKDD Test-of-Time Award 2014. Tidak seperti algoritma clustering berbasis partisi (seperti K-Means) atau berbasis hierarki, DBSCAN dapat menemukan kluster dengan bentuk arbitrari dan secara otomatis mengklasifikasikan titik-titik yang

tidak termasuk kluster manapun sebagai noise inilah fitur yang menjadikannya sangat relevan untuk deteksi anomali: titik-titik yang dilabeli sebagai noise oleh DBSCAN adalah kandidat anomali yang kuat. Algoritma ini hanya memerlukan dua parameter: epsilon (eps, radius neighborhood) dan MinPts (jumlah minimum titik yang diperlukan untuk membentuk kluster padat).

DBSCAN mendefinisikan tiga kategori titik: (1) Core point: titik p dengan setidaknya MinPts titik lain dalam radius eps-nya; (2) Border point: titik yang berada dalam radius eps dari sebuah core point tetapi tidak memiliki cukup tetangga untuk menjadi core point sendiri; (3) Noise point (outlier): titik yang bukan core point maupun border point dari kluster manapun. Schubert et al. (2017) dalam 'DBSCAN Revisited, Revisited' menegaskan bahwa klaim bahwa DBSCAN tidak dapat diimplementasikan secara efisien adalah keliru dan bahwa dengan indexing yang tepat (seperti R-tree), DBSCAN dapat mencapai performa yang kompetitif. Mereka juga memberikan panduan heuristik untuk memilih parameter eps yang optimal menggunakan k-distance plot.

Bin Shiraj et al. (2024) dalam penelitian mereka mengenai deteksi anomali dalam data perdagangan Bitcoin menggunakan Mapper algorithm dan DBSCAN clustering menunjukkan bahwa DBSCAN berhasil mengidentifikasi 44 data point sebagai anomali yang berkorespondensi dengan pergerakan harga ekstrem dalam deret waktu. Validasi menggunakan SVM mengkonfirmasi keberadaan anomali tersebut, tetapi pendekatan Mapper-DBSCAN memberikan separasi yang lebih jelas antara data normal dan anomali. Studi ini menegaskan relevansi DBSCAN untuk deteksi anomali dalam data keuangan yang bersifat deret waktu. Jain, Bajpai, dan Pamula (2022) mengusulkan modified DBSCAN untuk data deret waktu bersifat seasonal yang menambahkan atribut circular coordinate untuk menangkap pola musiman, meningkatkan jumlah anomali yang terdeteksi dari 2,16% menjadi 4,79%.

Chen et al. (2020) mengaplikasikan DBSCAN untuk deteksi anomali KPI (Key Performance Indicators) dalam manajemen jaringan telekomunikasi secara unsupervised, mencapai F-Score sekitar 0,9 untuk beberapa jenis KPI. Penelitian ini menunjukkan bahwa DBSCAN efektif untuk data unlabeled dalam konteks monitoring sistem yang bersifat deret waktu. Dalam penelitian ini, DBSCAN akan diterapkan pada data makroekonomi yang telah dinormalisasi dan direduksi dimensinya menggunakan PCA (sebagai preprocessing). Parameter eps akan ditentukan menggunakan k-distance plot dengan $k=5$, dan MinPts akan disetel pada nilai

yang memungkinkan deteksi kluster makroekonomi yang bermakna umumnya minimal 10-30 negara per kluster untuk memastikan interpretabilitas ekonomi. Kelebihan utama DBSCAN dalam konteks ini adalah kemampuannya menangkap clustering geometry yang arbitrari dari perekonomian-perekonomian yang memiliki profil makroekonomi serupa, dan secara otomatis mengidentifikasi perekonomian-perekonomian yang tidak sesuai dengan kluster manapun sebagai outlier/anomali.

2.2 Penelitian Terkait

Untuk mengidentifikasi kebaruan serta memetakan posisi penelitian terhadap studi-studi terdahulu, berikut disajikan perbandingan literatur komprehensif yang mencakup seluruh paper yang telah dikaji dalam penelitian ini. Parameter yang dibandingkan meliputi penulis, judul, fokus/konteks, data, dan metode yang digunakan.

No.	Penulis (Tahun)	Judul	Konteks & Data	Metode
1	Kaminsky, Lizondo & Reinhart (1997)	Leading Indicators of Currency Crises	Currency crises, 15 negara; data indikator makroekonomi pra-krisis (ekspor, cadangan, nilai tukar)	Signal extraction approach; threshold-based monitoring of individual indicators
2	Breunig, Kriegel, Ng & Sander (2000)	LOF: Identifying Density-Based Local Outliers	Foundational anomaly detection; dataset sintetik dan real-world (SEQUOIA 2000 benchmark)	Local Outlier Factor (LOF); density-based local outlier scoring
3	Ester, Kriegel, Sander & Xu (1996)	A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise	Clustering database spasial; dataset sintetik dan SEQUOIA 2000	DBSCAN; density-based clustering dengan noise point detection
4	Liu, Ting & Zhou (2008)	Isolation Forest	Anomaly detection benchmark; dataset UCI dan sintetik berdimensi tinggi	Isolation Forest (iForest); tree-based anomaly isolation
5	Sakurada & Yairi (2014)	Anomaly Detection Using Autoencoders with Nonlinear Dimensionality Reduction	Telemetri pesawat ruang angkasa; data multivariate time series Lorenz system	Autoencoder neural network; perbandingan dengan PCA dan Kernel PCA
6	Holopainen & Sarlin (2016)	Toward Robust Early-Warning Models: A	Systemic financial crises; data negara-negara Eropa	Perbandingan komprehensif: logit, probit, k-NN, neural network, ensemble methods


No.	Penulis (Tahun)	Judul	Konteks & Data	Metode
		Horse Race, Ensembles and Model Uncertainty		
7	Schubert, Sander, Ester, Kriegel & Xu (2017)	DBSCAN Revisited, Revisited: Why and How You Should (Still) Use DBSCAN	Revisit DBSCAN; dataset benchmark dan sintetik berbagai ukuran	DBSCAN dengan analisis kompleksitas dan panduan parameter
8	Auskalnis, Paulauskas & Baskys (2018)	Application of LOF Algorithm to Detect Anomalies in Computer Network	Intrusion detection; NSL-KDD dataset jaringan komputer	Local Outlier Factor (LOF) untuk anomaly-based IDS
9	Budiarto, Permanasari & Fauziati (2019)	Unsupervised Anomaly Detection Using K-Means, LOF and One Class SVM	Data penggunaan obat RS; dataset time-series mingguan	K-Means, LOF, One-Class SVM perbandingan performa
10	Qiao et al. (2021)	Efficient Anomaly Detection for High-Dimensional Sensing Data with One-Class SVM	IoT sensing data berdimensi tinggi; empat dataset dunia nyata	OCSVM + Deep Belief Network untuk kompresi dimensi
11	Kim et al. (2023)	Active Anomaly Detection Based on Deep One-Class Classification	Anomaly detection 7 benchmark dataset	Deep SVDD + active learning dengan noise-contrastive estimation
12	Al Farizi, Hidayah & Rizal (2021)	Isolation Forest Based Anomaly Detection: A Systematic Literature Review	Review 17 studi iForest; berbagai domain aplikasi	Systematic literature review; analisis kelemahan dan solusi iForest
13	Yousfani et al. (2025)	Global Shocks and Local Fragilities: A Financial Stress Index Approach to Pakistan	Stabilitas keuangan Pakistan 2005–2024; data bulanan multidimensi	PCA untuk konstruksi FSI; validasi dengan FSI global
Penelitian Ini		Analisis Deteksi Anomali pada Indikator	Panel data 49 negara, 1990–2024; 16 indikator World Bank Global Economic Monitor	Isolation Forest, LOF, Autoencoder, OCSVM, PCA-based, DBSCAN komparatif

No.	Penulis (Tahun)	Judul	Konteks & Data	Metode
		Makroekonomi Global sebagai Instrumen EWS Krisis Ekonomi		

Berdasarkan tabel perbandingan di atas, penelitian ini memiliki kebaruan yang signifikan pada beberapa dimensi. Pertama, cakupan geografis dan temporal yang sangat luas: mencakup 49 negara dengan data dari 1990 hingga 2024, jauh melampaui cakupan studi-studi terdahulu yang umumnya berfokus pada satu negara atau satu kawasan. Kedua, komparasi enam algoritma deteksi anomali yang berbeda paradigma secara simultan pada dataset yang sama, yang memungkinkan perbandingan empiris yang fair dan komprehensif. Ketiga, orientasi langsung pada konteks EWS krisis ekonomi multivariat dengan validasi historis, membedakannya dari studi-studi yang menerapkan algoritma deteksi anomali pada domain lain (jaringan komputer, IoT, keuangan mikro). Keempat, penggunaan dataset indikator makroekonomi komprehensif dari World Bank yang merupakan standar internasional, memberikan reproducibility dan generalizability yang tinggi.

2.3 Kerangka Pikir

Kerangka pikir penelitian ini dibangun di atas empat pilar yang saling berkaitan. Pertama, Permasalahan: (a) krisis ekonomi global yang berulang dan destruktif mengindikasikan kegagalan sistem peringatan dini konvensional; (b) heterogenitas dan multidimensionalitas data makroekonomi membuat pendekatan statistik tradisional kurang memadai; (c) belum adanya studi komparatif sistematis mengenai efektivitas berbagai paradigma unsupervised anomaly detection untuk EWS makroekonomi. Kedua, Solusi: pemanfaatan teknik unsupervised anomaly detection berbasis machine learning yang tidak bergantung pada label krisis historis dan mampu menangkap pola non-linier dalam data multivariat. Ketiga, Metode: penerapan komparatif enam algoritma Isolation Forest, LOF, Autoencoder, OCSVM, PCA, DBSCAN terhadap dataset makroekonomi global yang telah dipreproses secara komprehensif. Keempat, Output dan Evaluasi: peta distribusi spasial dan temporal anomali makroekonomi global, identifikasi algoritma optimal berdasarkan AUC-ROC, F1-Score, dan Precision-Recall curve, serta rekomendasi sistem EWS yang dapat



Gambar 1. Kerangka Penelitian

BAB III

METODOLOGI

3.1 Data

3.1.1 Sumber dan Cakupan Data

Penelitian ini menggunakan panel data makroekonomi yang bersumber dari World Bank Global Economic Monitor (GEM), salah satu database ekonomi makro terlengkap dan paling diakui secara internasional. Dataset penelitian ini mencakup 49 negara yang dipilih secara purposive berdasarkan representasi kawasan geografis utama dunia serta kelompok ekonomi strategis global. Pemilihan negara dilakukan dengan mengelompokkan sampel ke dalam beberapa kategori, yaitu negara G7, BRICS, ASEAN, negara Asia lainnya, Amerika Latin, Timur Tengah & Afrika, Eropa, serta Oseania. Pendekatan ini digunakan untuk memastikan keterwakilan negara maju, berkembang, dan emerging economies dalam analisis.

Secara rinci, kelompok negara yang digunakan dalam penelitian meliputi:

- G7: Amerika Serikat, Inggris, Jerman, Prancis, Italia, Jepang, dan Kanada
- BRICS: Brasil, Rusia, India, Tiongkok, dan Afrika Selatan
- ASEAN: Indonesia, Thailand, Malaysia, Filipina, Vietnam, dan Singapura
- Asia lainnya: Korea Selatan, Pakistan, Bangladesh, dan Sri Lanka
- Amerika Latin: Meksiko, Argentina, Kolombia, Chili, dan Peru
- Timur Tengah & Afrika: Arab Saudi, Turki, Mesir, Nigeria, Kenya, dan Uni Emirat Arab
- Eropa (non-G7): Spanyol, Belanda, Swedia, Norwegia, Polandia, Yunani, Portugal, Irlandia, Swiss, Austria, Belgia, Ceko, Hungaria, dan Rumania
- Oseania: Australia dan Selandia Baru

Dataset mencakup periode waktu 1990–2024, sehingga setelah proses *data cleaning* dan *preprocessing* diperoleh 1.715 observasi bersih yang digunakan dalam tahap analisis selanjutnya. Pendekatan pemilihan negara berbasis representasi kawasan dan blok ekonomi ini membantu meningkatkan validitas eksternal penelitian, karena hasil analisis tidak hanya merepresentasikan satu wilayah tertentu, tetapi menggambarkan pola global.

3.1.2 Variabel Penelitian

Dataset mencakup 16 indikator makroekonomi yang dipilih berdasarkan relevansinya sebagai sinyal potensial kerentanan ekonomi menurut literatur EWS (Kaminsky et al., 1997; Holopainen & Sarlin, 2016):

No.	Variabel	Satuan	Relevansi EWS
1	economy	Kode ISO negara	Identifikasi unit observasi
2	year	Tahun (1990–2024)	Dimensi temporal
3	GDP_Growth	% tahunan	Siklus bisnis, resesi
4	GDP PerCapita Growth	% tahunan	Kesejahteraan per kapita
5	Inflation_CPI	% tahunan	Stabilitas harga
6	Total_Reserves	USD	Ketahanan eksternal
7	Unemployment	% angkatan kerja	Kondisi pasar tenaga kerja
8	Current_Account_GDP	% PDB	Keseimbangan eksternal
9	Trade_GDP	% PDB	Keterbukaan perdagangan
10	FDI_Inflows_GDP	% PDB	Arus modal asing
11	Exports_GDP	% PDB	Daya saing ekspor
12	Imports_GDP	% PDB	Ketergantungan impor
13	Gross_Savings_GDP	% PDB	Kapasitas tabungan domestik
14	Exchange_Rate	LCU per USD	Stabilitas nilai tukar
15	Manufacturing_Value	% PDB	Diversifikasi sektor riil
16	Investment_GDP	% PDB	Investasi domestik bruto

3.1.3 Preprocessing Data

Tahap preprocessing data dilakukan secara sistematis untuk memastikan kualitas dataset sebelum digunakan dalam proses analisis. Proses ini mencakup beberapa langkah utama. Pertama, penanganan missing values dilakukan menggunakan pendekatan forward fill pada data runtut waktu dalam satu negara untuk menjaga kontinuitas temporal, serta median imputation berbasis kelompok kawasan geografis untuk mempertahankan karakteristik heterogenitas regional antarnegara.

Kedua, dilakukan deteksi dan penanganan outlier ekstrem, khususnya pada nilai yang secara statistik tidak realistis, seperti tingkat inflasi yang sangat tinggi (misalnya di atas 1000%)

yang berpotensi merepresentasikan kondisi hiperinflasi. Nilai-nilai tersebut ditandai dan diverifikasi kembali dengan merujuk pada sumber data primer agar tidak mengganggu stabilitas analisis.

Ketiga, seluruh variabel numerik menjalani proses standardisasi menggunakan metode Z-score standardization (mean = 0 dan standar deviasi = 1) untuk memastikan kesetaraan skala antarvariabel sehingga setiap indikator memiliki kontribusi yang proporsional dalam perhitungan jarak pada metode deteksi anomali yang digunakan.

Keempat, dilakukan feature engineering melalui penambahan variabel `crisis_label` sebagai label validasi eksternal yang disusun berdasarkan katalog krisis historis dari literatur terdahulu, seperti Kaminsky et al. (1997), serta basis data krisis yang dikembangkan World Bank. Variabel ini digunakan sebagai referensi pembandingan dalam mengevaluasi hasil deteksi anomali yang dihasilkan model.

3.2 Metode

3.2.1 Kerangka Komparatif Enam Algoritma

Penelitian ini membandingkan enam algoritma anomaly detection menggunakan pipeline evaluasi yang seragam untuk memastikan perbandingan yang objektif. Seluruh algoritma menggunakan input data yang sama, yaitu matriks fitur dengan 14 variabel numerik terstandardisasi, tanpa menyertakan variabel identifikasi seperti `economy` dan `year`.

Tahap preprocessing dilakukan secara konsisten menggunakan `StandardScaler`, sedangkan evaluasi kinerja model menggunakan metrik AUC-ROC, Precision, Recall, F1-Score, dan Average Precision (AP). Selain itu, validasi hasil deteksi dilakukan dengan membandingkan prediksi model terhadap variabel `crisis_label` sebagai ground truth eksternal. Pendekatan ini memastikan bahwa perbandingan performa antara algoritma dilakukan secara adil dan terstandarisasi.

3.2.2 Implementasi Isolation Forest

Isolation Forest diimplementasikan menggunakan library `scikit-learn` dengan konfigurasi yang terstandarisasi. Jumlah estimator ditetapkan sebesar 100, sesuai rekomendasi umum untuk mencapai konvergensi performa model. Parameter `contamination` yang merepresentasikan proporsi anomali yang diharapkan dikalibrasi berdasarkan frekuensi historis krisis dalam dataset (sekitar 5-15%) sebagai pendekatan berbasis prior. Parameter `max_samples` ditetapkan sebesar 256

untuk menjaga efisiensi komputasi tanpa mengorbankan performa secara signifikan, sedangkan `random_state` diatur untuk memastikan reproduktibilitas hasil.

Model menghasilkan anomaly score kontinu, di mana nilai yang lebih rendah menunjukkan tingkat anomali yang lebih tinggi. Penentuan label biner (anomali vs normal) dilakukan berdasarkan ambang (threshold) yang diturunkan dari nilai contamination yang telah dikalibrasi. Selain itu, dilakukan analisis sensitivitas dengan memvariasikan parameter contamination dalam rentang 0,03-0,20 untuk mengevaluasi stabilitas dan robustness model terhadap perubahan asumsi proporsi anomali.

3.2.3 Implementasi Local Outlier Factor

Algoritma Local Outlier Factor (LOF) diimplementasikan dengan parameter utama `n_neighbors` (k) yang ditentukan melalui grid search pada rentang {5, 10, 15, 20, 30, 50}, menggunakan nilai AUC-ROC terhadap `crisis_label` sebagai kriteria pemilihan parameter terbaik. Metric jarak yang digunakan adalah Euclidean (Minkowski, $p = 2$) karena data telah dinormalisasi sebelumnya. Parameter algorithm ditetapkan pada `auto` agar metode pencarian tetangga terdekat menyesuaikan secara otomatis dengan ukuran dataset.

Parameter contamination dikalibrasi secara konsisten dengan pendekatan yang digunakan pada Isolation Forest. Skor anomali dihasilkan dari atribut `negative_outlier_factor_`, yang kemudian dikonversi ke skala positif untuk memudahkan interpretasi. Selain itu, dilakukan evaluasi tambahan terhadap kemampuan LOF dalam mendeteksi contextual anomaly, yaitu kondisi perekonomian yang menyimpang relatif terhadap kelompok negara sebayanya berdasarkan kawasan geografis atau karakteristik ekonomi. Evaluasi waktu komputasi juga dilakukan mengingat kompleksitas LOF sebesar $O(n^2)$

3.2.4 Implementasi Autoencoder Neural Network

Autoencoder diimplementasikan menggunakan TensorFlow/Keras dengan arsitektur sederhana yang terdiri dari input layer 14 neuron, kemudian dua hidden layer (64 dan 32 neuron dengan aktivasi ReLU), bottleneck layer 8 neuron, serta decoder yang simetris hingga output layer 14 neuron dengan aktivasi linear.

Model dilatih menggunakan optimizer Adam (learning rate 0.001) dan loss function Mean Squared Error (MSE). Proses pelatihan menggunakan batch size 32 dengan maksimal 200 epoch dan teknik early stopping (patience 20) berdasarkan validation loss untuk mencegah overfitting.

Data dibagi menjadi 70% data latih (hanya data normal dengan label `crisis_label = 0`), 15% data validasi, dan 15% data uji. Untuk menentukan anomali, digunakan threshold berdasarkan persentil ke-95 dari reconstruction error pada data latih.

Reconstruction error dihitung menggunakan MSE per sampel, yaitu selisih rata-rata kuadrat antara input dan hasil rekonstruksi pada 14 fitur data.

3.2.5 Implementasi One-Class SVM

One-Class SVM (OCSVM) diimplementasikan menggunakan library scikit-learn dengan kernel RBF (Radial Basis Function). Parameter utama yang dioptimalkan adalah ν dan γ melalui grid search, dengan evaluasi menggunakan metrik AUC-ROC pada validation set.

Untuk mengurangi beban komputasi, model dilatih menggunakan teknik subsampling, yaitu hanya pada 70% data normal (`crisis_label = 0`), kemudian digunakan untuk melakukan scoring pada seluruh dataset. OCSVM menghasilkan decision function berupa skor kontinu yang menunjukkan tingkat deviasi data terhadap boundary normal, sehingga dapat digunakan untuk deteksi anomali dan perhitungan AUC-ROC.

Karena OCSVM sensitif terhadap skala data, dilakukan preprocessing menggunakan StandardScaler. Selain itu, dilakukan perbandingan dengan RobustScaler dan MinMaxScaler untuk melihat pengaruh metode scaling terhadap performa model..

3.2.6 Implementasi PCA-based Anomaly Detection

Deteksi anomali berbasis PCA menggunakan dua pendekatan utama, yaitu Squared Prediction Error (SPE) dan Hotelling's T-squared (T2). PCA dilatih menggunakan data normal (`crisis_label = 0`), kemudian jumlah komponen utama ditentukan berdasarkan cumulative explained variance minimal 95%. SPE digunakan untuk mengukur selisih antara data asli dan hasil rekonstruksi dari komponen utama, sedangkan T2 mengukur jarak setiap observasi dalam ruang komponen utama berdasarkan eigenvalue.

Untuk menentukan anomali, digunakan batas kendali (Upper Control Limit/UCL). Observasi yang melebihi UCL pada SPE atau T2 dikategorikan sebagai anomali. SPE

menggunakan pendekatan distribusi chi-square, sedangkan T2 menggunakan distribusi F. Selain itu, dilakukan contribution plot untuk mengidentifikasi variabel yang paling berkontribusi terhadap terjadinya anomali pada setiap kejadian krisis yang terdeteksi.

3.2.7 Implementasi DBSCAN

DBSCAN diterapkan pada data yang telah dinormalisasi dan direduksi dimensinya menggunakan PCA dengan mempertahankan 95% varians. Langkah ini dilakukan untuk mengurangi kompleksitas data dan mengatasi masalah dimensi tinggi.

Parameter eps ditentukan menggunakan metode k-distance plot, menghitung jarak ke tetangga terdekat ($k = \text{MinPts} - 1$), kemudian mengurutkan jarak tersebut untuk menemukan titik “elbow” sebagai nilai eps optimal. Nilai MinPts ditetapkan sebesar 15 berdasarkan pertimbangan minimal ukuran kluster yang bermakna dalam konteks data makroekonomi.

DBSCAN mengelompokkan data menjadi core point, border point, dan noise. Data yang terklasifikasi sebagai noise (label -1) dianggap sebagai anomali dalam sistem Early Warning System (EWS). Selain deteksi anomali, dilakukan analisis distribusi kluster untuk mengidentifikasi pola makroekonomi yang berulang serta memberikan interpretasi terhadap karakteristik masing-masing kluster.

3.3 Alur Penelitian (Research Workflow)

Alur penelitian ini terdiri dari delapan tahap yang berjalan secara berurutan dan saling bergantung, dirancang untuk memastikan reproduktibilitas dan validitas hasil.

Tahap 1 Akuisisi dan Verifikasi Data: Data indikator makroekonomi diperoleh dari World Bank Global Economic Monitor API dan diverifikasi konsistensinya dengan sumber primer. Informasi krisis historis dikompilasi dari publikasi World Bank untuk membangun variabel `crisis_label` sebagai referensi validasi eksternal

Tahap 2 Preprocessing Komprehensif: Tahap preprocessing meliputi penanganan missing values menggunakan forward fill dan median imputation, deteksi outlier ekstrem, standarisasi variabel menggunakan Z-score, serta konstruksi variabel `crisis_label`. Hasil tahap ini menghasilkan dataset `data_cleaned.csv` dan `data_with_labels.csv`.

Tahap 3 Eksplorasi Data (EDA): EDA dilakukan untuk menganalisis distribusi variabel, korelasi antar-indikator, pola temporal dan lintas negara (cross-country), serta perbedaan

karakteristik antara periode normal dan periode krisis sebagai dasar pemahaman awal terhadap struktur data.

Tahap 4 Kalibrasi Parameter: Kalibrasi parameter dilakukan menggunakan grid search untuk memperoleh konfigurasi optimal pada setiap algoritma, meliputi contamination rate (Isolation Forest dan LOF), ν dan γ (OCSVM), arsitektur serta learning rate (Autoencoder), jumlah principal component (PCA), serta ϵ dan MinPts (DBSCAN). Proses kalibrasi memanfaatkan sebagian data berlabel sebagai data validasi.

Tahap 5 Penerapan Enam Algoritma: Keenam algoritma diterapkan pada dataset yang sama menggunakan pipeline preprocessing yang seragam. Setiap algoritma menghasilkan anomaly score kontinu dan label biner anomali/normal berdasarkan threshold yang telah dikalibrasi.

Tahap 6 Evaluasi dan Seleksi Model: Kinerja algoritma dibandingkan menggunakan metrik evaluasi yang telah ditetapkan. Selain itu, dilakukan pendekatan ensemble untuk menggabungkan hasil dari algoritma dengan performa terbaik guna meningkatkan akurasi deteksi.

Tahap 7 Validasi Eksternal: Hasil deteksi anomali dibandingkan dengan katalog krisis historis dari International Monetary Fund dan World Bank untuk mengevaluasi kesesuaian temporal dan geografis sebagai indikator kemampuan prediktif sistem Early Warning System (EWS) yang dikembangkan.

Tahap 8 Interpretasi dan Visualisasi: Visualisasi distribusi spasial dan temporal anomali global, identifikasi variabel kontributor utama pada episode krisis, dan perumusan rekomendasi kebijakan berdasarkan temuan penelitian.

3.4 Matriks Evaluasi

3.4.1 Area Under the ROC Curve (AUC-ROC)

AUC-ROC (Area Under the Receiver Operating Characteristic Curve) digunakan sebagai metrik evaluasi utama dalam penelitian ini karena mampu mengukur kemampuan diskriminatif algoritma pada berbagai kemungkinan threshold secara simultan, sehingga tidak bergantung pada satu nilai threshold tertentu. Kurva ROC menggambarkan hubungan antara True Positive Rate (Recall) dan False Positive Rate (FPR) pada berbagai nilai threshold anomaly score.

Nilai AUC berada pada rentang 0,5 hingga 1,0, di mana nilai 0,5 menunjukkan performa setara random classifier, sedangkan nilai yang mendekati 1,0 menunjukkan kemampuan klasifikasi

yang sangat baik. Dalam konteks deteksi anomali makroekonomi, di mana kejadian krisis bersifat relatif jarang (imbalanced class), AUC-ROC dinilai lebih representatif dibandingkan metrik akurasi sederhana karena mampu menggambarkan kualitas pemisahan antara kondisi normal dan krisis secara lebih komprehensif.

3.4.2 F1-Score dan Precision-Recall Curve

Mengingat dataset memiliki ketidakseimbangan kelas (episode krisis sebagai kelas minoritas), digunakan F1-Score dan Average Precision (AP) sebagai metrik evaluasi sekunder yang lebih sensitif terhadap performa deteksi pada kelas minoritas. F1-Score merupakan rata-rata harmonik antara precision dan recall, sehingga mencerminkan kemampuan model dalam mendeteksi sebagian besar episode krisis sekaligus meminimalkan false alarm.

Sementara itu, Average Precision (AP) digunakan untuk mengevaluasi kualitas model berdasarkan luas area di bawah Precision–Recall curve, yang lebih informatif dibandingkan metrik berbasis akurasi pada kondisi data tidak seimbang. Kedua metrik ini dilaporkan pada threshold optimal yang ditentukan berdasarkan nilai F1-Score terbaik pada validation set, sehingga evaluasi performa model tetap konsisten dan representatif terhadap tujuan deteksi krisis makroekonomi.

3.4.3 Silhouette Index untuk Evaluasi DBSCAN

Untuk algoritma DBSCAN yang menghasilkan struktur klaster (bukan hanya label anomali), Digunakan Silhouette Index (SI) sebagai metrik evaluasi kualitas clustering yang tidak bergantung pada label eksternal. Silhouette Index mengukur keseimbangan antara kohesi intra-klaster dan separasi antar-klaster, sehingga dapat menggambarkan seberapa baik setiap observasi ditempatkan dalam klasternya.

Nilai SI berada pada rentang -1 hingga 1, di mana nilai mendekati 1 menunjukkan kualitas klaster yang baik, nilai mendekati 0 menunjukkan observasi berada di batas antar-klaster, dan nilai negatif mengindikasikan penugasan klaster yang kurang tepat. Dalam penelitian ini, nilai rata-rata Silhouette Index digunakan untuk mengevaluasi kualitas keseluruhan struktur klaster yang dihasilkan oleh DBSCAN sebagai bagian dari proses penilaian performa model.

3.4.4 Davies-Bouldin Index (DBI)

Davies–Bouldin Index (DBI) digunakan sebagai metrik evaluasi clustering internal komplementer untuk menilai kualitas klaster yang dihasilkan algoritma DBSCAN. Indeks ini

mengukur rasio antara jarak intra-klaster (scatter) dan jarak antar-centroid klaster (separasi), sehingga dapat menggambarkan tingkat kekompakan dan keterpisahan antar klaster.

Nilai DBI yang lebih rendah menunjukkan struktur klaster yang lebih baik, yaitu klaster yang semakin kompak dan saling terpisah secara jelas. Dalam penelitian ini, DBI digunakan bersama Silhouette Index untuk mengevaluasi kualitas hasil clustering serta membantu menentukan parameter DBSCAN yang optimal.

3.5 Target Penelitian

1. Teridentifikasinya observasi-observasi dalam dataset makroekonomi global (49 negara, 1990-2024) yang merupakan anomali statistik dalam ruang indikator makroekonomi 14-dimensi, dengan tingkat akurasi yang tervalidasi terhadap data krisis historis.
2. Diketuinya algoritma unsupervised anomaly detection yang paling optimal untuk konteks data makroekonomi global berdasarkan perbandingan komprehensif metrik AUC-ROC, F1-Score, Precision, Recall, dan Average Precision dari keenam algoritma yang diuji.
3. Tersusunnya peta distribusi spasial dan temporal anomali makroekonomi global yang menunjukkan pola geografis dan temporal episode-episode kerentanan ekonomi, yang dapat digunakan sebagai basis analisis kebijakan EWS.
4. Memberikan insight awal dalam pengembangan sistem EWS berbasis machine learning yang dapat diimplementasikan secara praktis oleh badan atau lembaga ekonomi.

DAFTAR PUSTAKA

- Al Farizi, W. S., Hidayah, I., & Rizal, M. N. (2021). Isolation forest based anomaly detection: A systematic literature review. *Proceedings of the 2021 4th International Conference on Information and Communications Technology (ICOIACT)*, Yogyakarta, Indonesia.
- Auskalnis, J., Paulauskas, N., & Baskys, A. (2018). Application of local outlier factor algorithm to detect anomalies in computer network. *Elektronika ir Elektrotechnika*, 24(3), 96–99. <https://doi.org/10.5755/j01.eie.24.3.20972>
- Bao, W., Yue, J., & Rao, Y. (2017). A deep learning framework for financial time series using stacked autoencoders and long-short term memory. *PLOS ONE*, 12(7), e0180944. <https://doi.org/10.1371/journal.pone.0180944>
- Bin Shiraj, M. M., Rahman, M. M., Al-Imran, M., Liza, M. Z. A., Murshed, M. M., & Akhter, N. (2024). Anomaly detection in financial time series data via mapper algorithm and DBSCAN clustering. *World Journal of Advanced Engineering Technology and Sciences*, 13(01), 070–084. <https://doi.org/10.30574/wjaets.2024.13.1.0396>
- Breunig, M. M., Kriegel, H.-P., Ng, R. T., & Sander, J. (2000). LOF: Identifying density-based local outliers. *Proceedings of ACM SIGMOD 2000 International Conference on Management of Data*, 93–104.
- Budiarto, E. H., Permanasari, A. E., & Fauziati, S. (2019). Unsupervised anomaly detection using K-means, local outlier factor and one class SVM. *2019 5th International Conference on Science and Technology (ICST)*. <https://doi.org/10.1109/ICST47872.2019>
- Chen, H., Yu, G., Liu, F., Cai, Z., Liu, A., Chen, S., et al. (2020). Unsupervised anomaly detection via DBSCAN for KPIs jitters in network managements. *Computers, Materials & Continua*, 62(2), 917–927. <https://doi.org/10.32604/cmc.2020.05981>
- Ding, Z., & Fei, M. (2013). An anomaly detection approach based on isolation forest algorithm for streaming data using sliding window. *3rd IFAC International Conference on Intelligent Control and Automation Science*, Chengdu, China.

Ester, M., Kriegel, H.-P., Sander, J., & Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. *Proceedings of the 2nd International Conference on Knowledge Discovery and Data Mining*, 226–231.

Geng, R., Bose, I., & Chen, X. (2015). Prediction of financial distress: An empirical study of listed Chinese companies using data mining. *European Journal of Operational Research*, 241(1), 236–247. <https://doi.org/10.1016/j.ejor.2014.08.016>

Holopainen, M., & Sarlin, P. (2016). Toward robust early-warning models: A horse race, ensembles and model uncertainty. *ECB Working Paper Series No. 1900*.

Hong, S., Wu, H., Xu, X., & Xiong, W. (2022). Early warning of enterprise financial risk based on decision tree algorithm. *Computational Intelligence and Neuroscience*, 2022, 9182099. <https://doi.org/10.1155/2022/9182099>

Jain, P., Bajpai, M. S., & Pamula, R. (2022). A modified DBSCAN algorithm for anomaly detection in time-series data with seasonality. *The International Arab Journal of Information Technology*, 19(1), 23–30. <https://doi.org/10.34028/iajit/19/1/3>

Kaminsky, G., Lizondo, S., & Reinhart, C. M. (1997). Leading indicators of currency crises. *World Bank Policy Research Working Paper No. 1852*.

Kim, M., Kim, J., Yu, J., & Choi, J. K. (2023). Active anomaly detection based on deep one-class classification. *Pattern Recognition Letters*, 167, 18–24. <https://doi.org/10.1016/j.patrec.2022.12.009>

Li, C., Guo, L., Gao, H., & Li, Y. (2021). Similarity-measured isolation forest: Anomaly detection method for machine monitoring data. *IEEE Transactions on Instrumentation and Measurement*, 70, 3512512. <https://doi.org/10.1109/TIM.2021.3062684>

Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation forest. *2008 IEEE International Conference on Data Mining (ICDM)*, 413–422. <https://doi.org/10.1109/ICDM.2008.17>

Qiao, Y., Wu, K., & Jin, P. (2021). Efficient anomaly detection for high-dimensional sensing data with one-class support vector machine. *IEEE Transactions on Knowledge and Data Engineering*. <https://doi.org/10.1109/TKDE.2021.3077046>

Sakurada, M., & Yairi, T. (2014). Anomaly detection using autoencoders with nonlinear dimensionality reduction. *Proceedings of the MLSDA 2014 Workshop*, 1–4. <https://doi.org/10.1145/2689746.2689747>

Schubert, E., Sander, J., Ester, M., Kriegel, H.-P., & Xu, X. (2017). DBSCAN revisited, revisited: Why and how you should (still) use DBSCAN. *ACM Transactions on Database Systems*, 42(3), Article 19. <https://doi.org/10.1145/3068335>

Susto, G. A., Beghi, A., & McLoone, S. (2017). Anomaly detection through on-line isolation forest: An application to plasma etching. *2017 28th Annual SEMI Advanced Semiconductor Manufacturing Conference (ASMC)*.

World Bank. (2024). *World Bank global economic monitor*. <https://datacatalog.worldbank.org/search/dataset/0037798>

Xu, D., Wang, Y., Meng, Y., & Zhang, Z. (2019). An improved data anomaly detection method based on isolation forest. *2019 International Conference on Intelligent Computing and its Emerging Applications (ICEA)*.

Yousfani, K., Iftikhar, H., Rodrigues, P. C., Armas, E. A. T., & López-Gonzales, J. L. (2025). Global shocks and local fragilities: A financial stress index approach to Pakistan's monetary and asset market dynamics. *Economies*, 13(8), 243. <https://doi.org/10.3390/economies13080243>