



Analisis Deteksi Anomali pada Indikator Makroekonomi Global sebagai Instrumen *Early Warning System* Krisis Ekonomi

AMIR SYAIFUDIN (222312968)
AGUSTINA BELADEWIANA MADU (222312947)
BRAMANTYO PUTRA RACHMANDANI (222313021)
M. REZKY RAYA KILWOUW (222313190)
MUHAMMAD DAFFA DEKANANDA (222313233)
NYIMAS VIRNA SALSA LESTARI RISQIA (222313307)

Latar Belakang

Sistem ekonomi global bersifat kompleks dan saling terhubung, sehingga rentan terhadap siklus boom-and-bust yang berulang, seperti pada Krisis Keuangan Asia 1997–1998, Krisis Keuangan Global 2008–2009, dan Pandemi COVID-19 2020.

Krisis menyebabkan kontraksi ekonomi besar, hilangnya triliunan dolar PDB, lonjakan inflasi dan pengangguran, serta memicu instabilitas sosial dan politik.



Keterlambatan deteksi yang mengakibatkan krisis sulit dikendalikan, sehingga memperlambat pemulihan ekonomi.



Diperlukan Early Warning System yang mampu menangkap pola non-linear serta anomali kompleks dalam data makroekonomi.

Limitasi Model Tradisional dan Solusi

Bagaimana dengan model konvensional?

Model statistik seperti logit dan probit mengandalkan asumsi distribusi tertentu serta hubungan linier antar variabel, padahal data makroekonomi bersifat multidimensional, non-linear, dan sering mengandung noise serta missing values.

Solusi yang Diajukan

Pendekatan unsupervised learning memungkinkan deteksi anomali tanpa bergantung pada label krisis, sehingga lebih fleksibel, adaptif, dan mampu menangkap pola tersembunyi dalam data.

Rumusan Masalah & Tujuan Penelitian

Rumusan Masalah

- Krisis berulang (Krisis Keuangan Asia 1997–1998, Krisis Keuangan Global 2008–2009, Pandemi COVID-19 2020) menunjukkan deteksi dini masih lemah.
- Model tradisional terbatas oleh asumsi kaku dan ketergantungan pada label data.
- Belum ada perbandingan komprehensif metode unsupervised anomaly detection.
- Kurangnya peta anomali global menghambat pemahaman pola krisis.

Tujuan

- Mendeteksi anomali pada data makroekonomi global (49 negara, 1990–2024) tanpa label krisis.
- Mengembangkan sistem EWS berbasis anomali untuk mengidentifikasi potensi pra-krisis.
- Membandingkan performa 6 algoritma unsupervised untuk menemukan metode paling optimal.
- Memvalidasi hasil dengan data krisis historis untuk menguji efektivitas model.

Gambaran Data

No	Variabel	Penjelasan	No	Variabel	Penjelasan
1	GDP_Growth	Pertumbuhan PDB tahunan.	8	FDI_Inflows_GDP	Rasio investasi asing masuk terhadap PDB.
2	GDP_PerCapita_Growth	Pertumbuhan PDB per kapita (kesejahteraan rata-rata).	9	Exports_GDP	Rasio ekspor terhadap PDB.
3	Inflation_CPI	Tingkat inflasi berdasarkan CPI.	10	Imports_GDP	Rasio impor terhadap PDB.
4	Total_Reserves	Cadangan devisa negara.	11	Gross_Savings_GDP	Rasio tabungan terhadap PDB.
5	Unemployment	Tingkat pengangguran	12	Exchange_Rate	Nilai tukar mata uang lokal per USD.
6	Current_Account_GDP	Rasio neraca berjalan terhadap PDB.	13	Manufacturing_Value	Kontribusi sektor manufaktur ke PDB.
7	Trade_GDP	Rasio total perdagangan terhadap PDB.	14	Investment_GDP	Rasio investasi terhadap PDB.

PIPELINE PRA-PEMROSESAN DATA



MISSING VALUE

Hybrid Approach: Interpolasi Linear untuk menjaga aspek Temporal, ditambah KNN Imputer untuk relasi Multivariat.



OUTLIER TREATMENT


Winsorizing (0.5%–99.5%): Membatasi nilai ekstrem tanpa menghapus "Sinyal Krisis" yang seringkali berada di ekor distribusi.



NORMALISASI

Z-Score Scaling: StandardScaler digunakan agar variabel dengan satuan berbeda (USD vs %) memiliki bobot yang seragam.


I KERANGKA ALUR PENELITIAN



Focus: Tahap Agregasi

Langkah krusial untuk mengurangi bias algoritma tunggal. Dengan memadukan 6 paradigma (Isolasi, Densitas, Deep Learning, dll.), sistem EWS menjadi lebih stabil dan robust terhadap variasi tipe krisis.

Isolation Forest



Ringkasan:

- Premis: Anomali itu sedikit dan berbeda jauh (ekstrem).
- Proses: Data dipotong-potong secara acak menggunakan pohon keputusan (Random Trees).
- Logika: Data anomali akan terpisah (terisolasi) lebih cepat dengan sedikit pemotongan karena posisinya yang jauh dari kerumunan.
- Hasil: Semakin pendek jalur sebuah data di dalam pohon, semakin besar kemungkinan data tersebut adalah anomali.

Kenapa Metode Dipilih?

01.

Sesuai Sifat Krisis (Langka & Ekstrem): Krisis ekonomi adalah kejadian langka dengan nilai fluktuasi yang ekstrem. Hal ini amat cocok dengan Isolation Forest yang didesain spesifik untuk mendeteksi data yang "minoritas dan berbeda".


02.

Tanpa Label Klasifikasi (Unsupervised): Menentukan batas pasti periode krisis seringkali subjektif. Kemampuan unsupervised memungkinkan algoritma ini mengidentifikasi anomali murni dari pola data tanpa bergantung pada label historis atau pendapat pakar.

03.

Bebas Asumsi Distribusi Data: Indikator ekonomi seringkali tidak berdistribusi normal. Algoritma ini lebih tangguh (robust) karena bekerja berdasar isolasi, bukan berdasar asumsi parameter uji statistik tertentu.

Local Outlier Factor



Ringkasan:

- **Fokus Lokal:** Ia tidak melihat data secara keseluruhan, tapi hanya membandingkan sebuah titik dengan kelompok terdekatnya (-neighbors).
- **Prinsip Kepadatan:** Jika sebuah titik jauh lebih renggang (sepi) dibanding tetangganya yang rapat, maka titik tersebut dianggap sebagai outlier.
- **Skor LOF:**
 - Jika skor mendekati 1, berarti titik tersebut normal.
 - Jika skor jauh lebih besar dari 1, berarti titik tersebut adalah pencilan (anomali).

Kenapa Metode Dipilih?

01.

Peka Terhadap Kepadatan Lokal (Local Density): LOF mengukur anomali berdasarkan perbedaan relatif dengan tetangga terdekatnya. Angka inflasi 8% mungkin "normal" di negara berkembang, tetapi menjadi "krisis" di benua Eropa. Pendekatan lokal ini mampu menangkap perbedaan konteks sosio-ekonomi tersebut.


02.

Adaptif pada Variasi Volatilitas Data: Kelompok negara maju biasanya sangat stabil (data mengumpul padat), sedangkan emerging market lebih fluktuatif (data menyebar longgar). LOF tidak akan bias dalam membandingkan perbedaan tingkat kepadatan gugus data tersebut.

03.

Interpretasi Tingkat Skor yang Jelas: Algoritma ini menderivasikan skor LOF secara proporsional kuantitatif (nilai di sekitar 1 dianggap wajar, nilai yang jauh lebih besar dari 1 adalah anomali). Hal ini memudahkan kita mengurutkan tingkat keparahan (peringkat) indikasi suatu krisis.

Autoencoder



Ringkasan:

- **Encoder:** Mengubah data input (dimensi tinggi) menjadi representasi yang lebih kecil atau padat.
- **Bottleneck:** Lapisan tengah dengan jumlah neuron paling sedikit. Di sini data dipaksa menjadi bentuk paling ringkas (kompresi).
- **Decoder:** Mengambil data ringkas dari *bottleneck* dan membangunnya kembali menjadi data asli.

Kenapa Metode Dipilih?

01.

Menangkap Hubungan Non-Linear Kompleks: Interaksi antar indikator ekonomi seringkali rumit dan tidak linear (misalnya efek inflasi terhadap garis pertumbuhan PDB). Arsitektur neural network pada Autoencoder sangat kuat dalam mempelajari pola korelasi multidimensi yang rumit ini.

02.


Mengekstraksi Faktor Ekonomi Esensial (Latent Representation): Lewat mekanisme bottleneck (penyempitan sinyal), algoritma ini memaksa mesin untuk hanya mempelajari inti fundamental struktur ekonomi yang sehat, dan otomatis mengabaikan noise (fluktuasi pasar kecil yang wajar).

03.

Metrik Alarm yang Intuitif (Reconstruction Error): Model yang telah fasih mengenali kondisi perekonomian normal akan secara dramatis gagal menduplikasi pola data saat disodorkan data masa krisis. Tingginya nilai kegagalan rekonstruksi ini berfungsi sebagai sinyal/alarm anomali yang sangat tegas.

One-Class SVM

Algoritma One-Class SVM merupakan ekstensi dari algoritma SVM untuk skenario one-class classification, di mana model dilatih secara eksklusif menggunakan data kondisi makroekonomi normal.



Model secara efektif menggambar batas di sekitar data normal. Titik data yang jatuh di luar batas ini diidentifikasi sebagai anomali atau sinyal distress ekonomi.

Kenapa Metode Dipilih?

01.

Fokus pada Kondisi Normal: Sangat efektif untuk data krisis yang langka (rare events) karena model hanya belajar dari pola ekonomi stabil sebagai referensi tunggal.

02.

Menangani Data Non-Linear: Menggunakan kernel trick (RBF) untuk menciptakan batas wilayah "sehat" yang fleksibel, sesuai dengan hubungan antar indikator ekonomi yang rumit.

03.

Kontrol Sensitivitas: Memiliki parameter ν (ν) yang memungkinkan peneliti mengatur ambang batas deteksi sesuai frekuensi historis krisis.

PCA-based

Konsep Dasar: Mengukur deviasi data dari manifold linear normal menggunakan dua metrik komplementer

Mekanisme Kerja:

- Reduksi Dimensi: Mengonversi 14 indikator menjadi komponen utama (Principal Components) yang saling independen dan mempertahankan varians kumulatif $\geq 95\%$
- Metrik Evaluasi:
 - **Squared Prediction Error (SPE):** Mengukur residu rekonstruksi; nilai tinggi menunjukkan data tidak sesuai dengan pola ekonomi normal.
 - **Hotelling's T^2** : Mengukur jarak Mahalanobis dalam ruang komponen utama untuk mendeteksi variasi ekstrem di dalam model.
- Ambang Batas (Threshold): Menggunakan Upper Control Limit (UCL) berbasis distribusi chi-squared (untuk SPE) dan distribusi F (untuk T^2)

Kenapa Metode Dipilih?

01.

Mereduksi Korelasi Antar-Variabel: Menangani multikolinearitas tinggi pada 14 indikator makroekonomi dengan mengubahnya menjadi komponen utama yang independen.

02.


Deteksi Residu Varians: Mengidentifikasi krisis sebagai penyimpangan yang tidak mampu direkonstruksi oleh pola ekonomi normal (menggunakan metrik SPE dan T^2).

03.

Diagnosis Pemicu: Memungkinkan penggunaan contribution plot untuk mengetahui variabel spesifik (seperti inflasi atau cadangan devisa) yang paling memicu sinyal anomali.

DBSCAN

Konsep Dasar: Algoritma clustering berbasis kepadatan yang secara otomatis memisahkan titik data yang tidak termasuk dalam kelompok manapun sebagai noise.



Mekanisme Kerja:

- Preprocessing: Diterapkan pada data yang telah direduksi dimensinya menggunakan PCA untuk mengatasi curse of dimensionality.
- Parameter Utama: Ditentukan melalui k-distance plot untuk mencari nilai Epsilon (radius) dan MinPts (minimal 15 observasi negara-tahun).
- Klasifikasi Titik: Membagi data menjadi Core Points, Border Points, dan Noise Points.
- Logika Deteksi: Titik yang dilabeli sebagai noise (label -1) diinterpretasikan sebagai anomali krisis.

Kenapa Metode Dipilih?

01.

Identifikasi Otomatis Anomali: Melabeli observasi yang terpencil di area jarang sebagai noise; ideal untuk mendeteksi krisis sebagai kondisi ekstrem dalam ruang ekonomi

02.

Tanpa Asumsi Jumlah Kluster: Tidak memerlukan penentuan jumlah kelompok di awal, sehingga mampu menemukan pola ekonomi lintas negara yang terbentuk secara alami.

03.

Menangani Heterogenitas: Mampu mengelompokkan negara-negara dengan profil serupa dan memisahkan negara yang "menyimpang" tanpa terpengaruh oleh titik ekstrem (outlier) global.

Validasi dan Matriks Evaluasi

AUC-ROC

Metrik utama — Mengukur kemampuan diskriminatif di seluruh threshold secara sekaligus. Tidak bergantung pada pemilihan threshold tertentu.

AUC = 0.5 → random
AUC = 1.0 → sempurna

F1-Score & Precision-Recall

Metrik sekunder — Sensitif terhadap kelas minoritas (krisis). Mengukur keseimbangan antara kemampuan menangkap krisis (Recall) dan akurasi sinyal (Precision).

Silhouette Index & DBI

Untuk DBSCAN — Evaluasi kualitas clustering internal. Silhouette: kohesi vs separasi. Davies-Bouldin: rasio scatter intra/inter-kluster.

Target Penelitian

Identifikasi Anomali Multivariat

Mendeteksi observasi anomali pada 14 indikator makroekonomi di 49 negara (1990-2024) dengan validasi data krisis historis

Optimisasi Algoritma

Menentukan algoritma terbaik melalui komparasi performa metrik AUC-ROC, F1-Score, dan Average Precision dari enam metode.

Pemetaan Spasial-Temporal

Menyusun peta pola kerentanan ekonomi global lintas wilayah dan periode sebagai basis analisis kebijakan EWS

Pengembangan Instrumen Praktis

Memberikan rekomendasi teknis sistem EWS berbasis machine learning untuk implementasi di lembaga ekonomi.